

Rjesenja – Integralni ispit iz Statistike

Grupa B, ak. 2025./26., Datum: 20.06.2026.

Pitanje 1: Statisticki skup

Ključni pojam

Statisticki skup (populacija) je skup svih jedinica (elemenata) koji posjeduju određeno zajedničko svojstvo i koji su predmet statističkog istraživanja.

Definicija: Statisticki skup je ukupnost svih elemenata koji imaju zajednički atribut od interesa za istraživanje. Može biti *konacan* ili *beskonacan*, *homogen* ili *heterogen*.

Primjeri:

- Svi studenti Internacionalnog univerziteta u Travniku u ak. 2025./26. godini.
- Svi građani grada A koji koriste usluge gradskog saobraćaja.
- Sve njemacke kompanije s više od 500 zaposlenih.

Pitanje 2: Prigodni uzorak

Ključni pojam

Uzorak je dio (podskup) statistickog skupa koji se bira radi analize, jer je istraživanje cijele populacije često skupo ili nemoguće.

Prigodni uzorak (engl. *convenience sample*) je vrsta nenamjernog (*neprobabilistickog*) uzorkovanja u kojoj se za uzorak biraju one jedinice koje su istraživačima najlakše dostupne, bez slučajnog mehanizma odabira.

Karakteristike:

- Brz i jeftin za prikupljanje podataka.
- Ne garantuje reprezentativnost – rezultati se ne mogu pouzdano generalizovati na cijelu populaciju.
- Podlozan *pristrasnosti uzorkovanja* (sampling bias).

Primjer: Anketiranje prvih 40 prolaznika ispred fakulteta o zadovoljstvu gradskim prevozom – osobe koje prođu su “prikladne”, ali ne odražavaju nužno mišljenje svih građana.

Pitanje 3: Modus i medijan

Ključni pojam

Modus i medijan su mjere centralne tendencije – opisuju tipicnu ili srednju vrijednost skupa podataka.

Modus (Mo) je vrijednost koja se u nizu podataka pojavljuje *najcesce*. Skup može imati jedan modus (unimodalan), dva modusa (bimodalan) ili više modusa (multimodalan). Ako se sve vrijednosti pojavljuju jednako često, modus ne postoji.

Primjer modusa: Za niz $\{3, 5, 5, 7, 9\}$, modus je $Mo = 5$.

Medijan (Me) je vrijednost koja dijeli uređeni niz podataka na dva jednaka dijela. Tačno polovina podataka je ispod, a polovina iznad medijana.

Racunanje medijana:

- Podaci se najpre uređuju od najmanje do najveće vrijednosti.
- Ako je n neparan: medijan je element na poziciji $\frac{n+1}{2}$.
- Ako je n paran: medijan je prosjek dva srednja elementa, na pozicijama $\frac{n}{2}$ i $\frac{n}{2} + 1$.

Primjer medijana: Za niz $\{2, 4, 5, 8, 10\}$ ($n = 5$, neparan):

$$Me = x_{\frac{5+1}{2}} = x_3 = 5.$$

Zadatak 4: Mjere disperzije za grupisane podatke

Dati podaci:

Duzina cekanja (min)	Sredina intervala x_i	Broj putnika f_i
2 – 4	3	2
4 – 6	5	14
6 – 8	7	17
8 – 10	9	7
Ukupno		$n = 40$

Zasto ovaj korak?

Za grupisane podatke koristimo *sredinu intervala* x_i kao reprezentativnu vrijednost tog razreda. Sve formule zatim koristimo sa parovima (x_i, f_i) .

Pomocni korak: Aritmeticka sredina $\bar{x}$

$$\bar{x} = \frac{\sum f_i \cdot x_i}{\sum f_i} \quad (0)$$

$$\sum f_i x_i = 2 \cdot 3 + 14 \cdot 5 + 17 \cdot 7 + 7 \cdot 9 = 6 + 70 + 119 + 63 = 258$$

$$\bar{x} = \frac{258}{40} = \boxed{6,45 \text{ min}}$$

Zasto ovaj korak?

Aritmeticka sredina je “centar tezista” raspodjele. Trebamo je za sve mjere disperzije koje slijede.

Pomocna tabela kvadratnih odstupanja

x_i	f_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$f_i(x_i - \bar{x})^2$
3	2	$3 - 6,45 = -3,45$	11,9025	23,805
5	14	$5 - 6,45 = -1,45$	2,1025	29,435
7	17	$7 - 6,45 = 0,55$	0,3025	5,1425
9	7	$9 - 6,45 = 2,55$	6,5025	45,5175
40				$\sum = 103,9$

a) Raspon varijacije (Range)

Kljucni pojam

Raspon varijacije R je razlika izmedju najvece i najmanje vrijednosti u skupu. To je najjednostavnija mjera disperzije.

$$R = x_{\max} - x_{\min}$$

Kod grupisanih podataka koristimo gornju granicu najveceg razreda i donju granicu najmanjeg:

$$R = 10 - 2 = \boxed{8 \text{ minuta}}$$

Zasto ovaj korak?

Raspon nam govori da se ukupna razlika u vremenu cekanja proteze na 8 minuta. Nedostatak: ovisi samo o dvjema krajnjim vrijednostima i ne uzima u obzir raspodjelu ostatka podataka.

b) Standardna devijacija σ

Ključni pojam

Varijansa σ^2 mjeri prosjecno kvadratno odstupanje od aritmetičke sredine. **Standardna devijacija** σ je drugi korijen varijanse i ima iste mjerne jedinice kao i originalni podaci.

Varijansa za grupisane podatke (populacija):

$$\sigma^2 = \frac{\sum f_i(x_i - \bar{x})^2}{\sum f_i} = \frac{103,9}{40} = 2,5975$$

$$\sigma = \sqrt{\sigma^2} = \sqrt{2,5975} \approx \boxed{1,612 \text{ min}}$$

Zasto ovaj korak?

Standardna devijacija $\sigma \approx 1,61$ min znaci da putnici u prosjeku cekaju oko 1,61 minutu vise ili manje od srednje vrijednosti od 6,45 minuta.

c) Koeficijent varijacije CV

Ključni pojam

Koeficijent varijacije je relativna mjera disperzije. Izrazava se kao postotak i omogućava poredjenje varijabilnosti skupova s razlicitim jedinicama ili sredinama.

$$CV = \frac{\sigma}{\bar{x}} \cdot 100\%$$

$$CV = \frac{1,612}{6,45} \cdot 100\% \approx \boxed{24,99\% \approx 25,0\%}$$

Zasto ovaj korak?

$CV \approx 25\%$ ukazuje na umjerenu varijabilnost. Opstim pravilom: $CV < 30\%$ – homogen skup; $CV \geq 30\%$ – heterogen skup. Dakle, duzine cekanja su relativno homogene oko srednje vrijednosti.

d) Koeficijent asimetrije (Pearsonov)

Ključni pojam

Koeficijent asimetrije (engl. *skewness*) mjeri stupanj i smjer nesimetričnosti raspodjele oko aritmetičke sredine. Koristimo **Pearsonov koeficijent asimetrije** koji je posebno pogodan za grupisane podatke.

Za grupisane podatke, modus intervalne serije nalazi se u razredu s najvećom frekvencijom. Razred 6–8 ima $f = 17$ (najveća frekvencija), pa je modus:

$$Mo = L + \frac{d_1}{d_1 + d_2} \cdot h$$

gdje je $L = 6$ (donja granica modalnog razreda), $h = 2$ (sirina razreda), $d_1 = 17 - 14 = 3$ (razlika s prethodnim), $d_2 = 17 - 7 = 10$ (razlika sa sljedećim):

$$Mo = 6 + \frac{3}{3 + 10} \cdot 2 = 6 + \frac{6}{13} \approx 6,46$$

Pearsonov koeficijent asimetrije:

$$Sk = \frac{\bar{x} - Mo}{\sigma} = \frac{6,45 - 6,46}{1,612} = \frac{-0,01}{1,612} \approx \boxed{-0,006}$$


Zasto ovaj korak?

$Sk \approx 0$ ukazuje na gotovo *simetricnu raspodjelu*.

- Ako je $Sk > 0$: pozitivna (desna) asimetrija – rep se proteže udesno.
- Ako je $Sk < 0$: negativna (lijeva) asimetrija – rep se proteže ulijevo.
- Ako je $Sk = 0$: savršena simetrija (normalna raspodjela).

Nasih $Sk \approx -0,006$ praktično znači da je raspodjela simetricna.

Vizualizacija – Histogram



Zadatak 5: Indeksni brojevi

Dati podaci:

Proizvod	q_0 (2014)	q_1 (2015)	p_0 (2014)	p_1 (2015)
A	19	25	2	3
B	16	19	6	9
C	20	13	7	11

gdje je q – kolicina, p – cijena, indeks $_0$ = bazna (2014), $_1$ = tekuca (2015) godina.

Ključni pojam

Agregatni indeksi mjere promjene ukupne vrijednosti, cijena ili kolicina grupe dobara izmedju dviju vremenskih tacaka. Bazna godina je 2014. ($= 100$), tekuca je 2015.

Pomocne velicine

Pr.	p_0q_0	p_1q_1	p_1q_0	p_0q_1
A	$2 \cdot 19 = 38$	$3 \cdot 25 = 75$	$3 \cdot 19 = 57$	$2 \cdot 25 = 50$
B	$6 \cdot 16 = 96$	$9 \cdot 19 = 171$	$9 \cdot 16 = 144$	$6 \cdot 19 = 114$
C	$7 \cdot 20 = 140$	$11 \cdot 13 = 143$	$11 \cdot 20 = 220$	$7 \cdot 13 = 91$
Σ	274	389	421	255

a) Agregatni indeks vrijednosti I_V

Ključni pojam

Agregatni indeks vrijednosti mjeri ukupnu promjenu vrijednosti (prihoda) u odnosu na baznu godinu. Obuhvata i promjenu cijena i promjenu kolicina.

$$I_V = \frac{\sum p_1q_1}{\sum p_0q_0} \cdot 100$$

$$I_V = \frac{389}{274} \cdot 100 = \boxed{141,97 \approx 142,0}$$

Zasto ovaj korak?

$I_V \approx 142$ znaci da je ukupna vrijednost prodaje sva tri proizvoda u 2015. godini veca za **42%** u odnosu na 2014. godinu. Porast je kombinovani efekt promjene i cijena i kolicina.

b) Laspeyresov i Paascheov indeks cijena i kolicina

Ključni pojam

Laspeyresov indeks ponderise promjene kolicinama (ili cijenama) iz bazne godine.

Paascheov indeks ponderise promjene kolicinama (ili cijenama) iz tekuće godine. Svaki pristup daje nešto drugaciju procjenu stvarne promjene.

Laspeyresov indeks cijena I_p^L

$$I_p^L = \frac{\sum p_1 q_0}{\sum p_0 q_0} \cdot 100 = \frac{421}{274} \cdot 100 = \boxed{153,65}$$

Zasto ovaj korak?

Laspeyresov indeks cijena pita: “Koliko bi kostala ista korpa dobara iz 2014. po cijenama iz 2015.?” Odgovor: **53,65% skuplje**.

Laspeyresov indeks kolicina I_q^L

$$I_q^L = \frac{\sum p_0 q_1}{\sum p_0 q_0} \cdot 100 = \frac{255}{274} \cdot 100 = \boxed{93,07}$$

Zasto ovaj korak?

Laspeyresov indeks kolicina mjeri promjenu fizickog obima prodaje vrednovanog po baznim cijenama. $I_q^L \approx 93$ znaci da su **kolicine smanjene za oko 6,93%**.

Paascheov indeks cijena I_p^P

$$I_p^P = \frac{\sum p_1 q_1}{\sum p_0 q_1} \cdot 100 = \frac{389}{255} \cdot 100 = \boxed{152,55}$$

Zasto ovaj korak?

Paascheov indeks cijena pita: “Za koliko su skuplje tekuće kolicine po tekucim u odnosu na bazne cijene?” Odgovor: **52,55% skuplje**.

Paascheov indeks kolicina I_q^P

$$I_q^P = \frac{\sum p_1 q_1}{\sum p_1 q_0} \cdot 100 = \frac{389}{421} \cdot 100 = \boxed{92,40}$$

Zasto ovaj korak?

Paascheov indeks kolicina ponderise tekucim cijenama. $I_q^P \approx 92$ potvrđuje smanjenje fizickog obima od oko **7,6%**.

Provjera osobine dekompozicije indeksa vrijednosti

Kljucni pojam

Osobina dekompozicije (Fisher-ova provjera) kaze da je agregatni indeks vrijednosti jednak proizvodu odgovarajucih Laspeyresovog indeksa cijena i Paascheovog indeksa kolicina (ili Paascheovog indeksa cijena i Laspeyresovog indeksa kolicina):

$$I_V = I_p^L \cdot I_q^P = I_p^P \cdot I_q^L$$

Provjera 1: $I_p^L \cdot I_q^P$

$$\frac{\sum p_1 q_0}{\sum p_0 q_0} \cdot \frac{\sum p_1 q_1}{\sum p_1 q_0} = \frac{\sum p_1 q_1}{\sum p_0 q_0} = I_V \quad \checkmark$$

Numericka provjera:

$$1,5365 \times 0,9240 = 1,4197 \approx I_V = 1,4197 \quad \checkmark$$

Provjera 2: $I_p^P \cdot I_q^L$

$$\frac{\sum p_1 q_1}{\sum p_0 q_1} \cdot \frac{\sum p_0 q_1}{\sum p_0 q_0} = \frac{\sum p_1 q_1}{\sum p_0 q_0} = I_V \quad \checkmark$$

Numericka provjera:

$$1,5255 \times 0,9307 = 1,4197 \approx I_V = 1,4197 \quad \checkmark$$

Zasto ovaj korak?

Osobina dekompozicije potvrđuje konzistentnost sistema indeksa: ukupnu promjenu vrijednosti mozemo razloziti na zasebne efekte promjene cijena i promjene kolicina. Ovo je kljucna analitika u ekonomskoj statistici jer pokazuje koji faktor vise doprinosi rastu vrijednosti. U nasem slucaju: vrijednost je porasla za 42%, gotovo iskljucivo zbog rasta cijena ($\approx +53\%$), dok je fizicki obim blago opao ($\approx -7\%$).

Zbirni pregled rezultata

Indeks	Vrijednost
Agregatni indeks vrijednosti I_V	142,0
Laspeyresov indeks cijena I_p^L	153,65
Laspeyresov indeks kolicina I_q^L	93,07
Paascheov indeks cijena I_p^P	152,55
Paascheov indeks kolicina I_q^P	92,40
Provjera: $I_p^L \times I_q^P$	$153,65 \times 0,9240 \approx 141,97 \checkmark$
Provjera: $I_p^P \times I_q^L$	$152,55 \times 0,9307 \approx 141,97 \checkmark$