

Regresiono-korelaciona analiza

Linearna regresija

Potpuna rješenja

Ključni pojam

Pregled ključnih formula:

$\hat{y}_i = a + b \cdot x_i$ – jednačina linearne regresije

$b = \frac{C_{XY}}{\sigma_x^2}$ – nagib regresione prave

$a = \bar{Y} - b \cdot \bar{X}$ – odsječak na osi y

$C_{XY} = \frac{\sum x_i \cdot y_i}{N} - \bar{X} \cdot \bar{Y}$ – kovarijansa

$\sigma_x^2 = \frac{\sum x_i^2}{N} - \bar{X}^2$, $\sigma_y^2 = \frac{\sum y_i^2}{N} - \bar{Y}^2$ – varijanse

$r^2 = \frac{C_{XY}^2}{\sigma_x^2 \cdot \sigma_y^2}$ – koeficijent determinacije

$r = \frac{C_{XY}}{\sigma_x \cdot \sigma_y}$ – koeficijent linearne korelacije

$\rho = 1 - \frac{6 \cdot \sum d_i^2}{N^3 - N}$, $d_i = r_x - r_y$ – Spearmanov koeficijent korelacije ranga

Tumačenje r : $|r| \in [0; 0,20]$ neznatna; $[0,20; 0,40]$ niska; $[0,40; 0,70]$ umjerena; $[0,70; 0,90]$ visoka; $[0,90; 1]$ veoma visoka; $r = 1$ perfektna korelacija.


Predznak r : $r > 0$ pozitivna (rastuća) veza; $r < 0$ negativna (opadajuća) veza.

Primjer 1 – Obim i troškovi proizvodnje (6 godina)

Dati podaci (x = obim proizvodnje u 000 kom, y = troškovi u 000 KM):

Godina	x_i	y_i
1	4	100
2	6	146
3	8	178
4	10	220
5	12	256
6	13	280

a) Oblak rasipanja



Zašto ovaj korak?

Dijagram rasipanja pokazuje jasnu **pozitivnu linearnu vezu** – kako obim raste, rastu i troškovi. Tačke su gotovo savršeno raspoređene uz zamišljenu pravac liniju.

b) Linearna regresiona funkcija

Pomoćna tabela:

x_i	y_i	$x_i \cdot y_i$	x_i^2	y_i^2
4	100	400	16	10000
6	146	876	36	21316
8	178	1424	64	31684
10	220	2200	100	48400
12	256	3072	144	65536
13	280	3640	169	78400
53	1180	11612	529	255336

Izračun pomoćnih veličina:

$$\bar{X} = \frac{\sum x_i}{N} = \frac{53}{6} = 8,83 \quad \bar{Y} = \frac{\sum y_i}{N} = \frac{1180}{6} = 196,67$$

$$\sigma_x^2 = \frac{\sum x_i^2}{N} - \bar{X}^2 = \frac{529}{6} - 8,83^2 = 88,17 - 77,97 = 10,2$$

$$C_{XY} = \frac{\sum x_i \cdot y_i}{N} - \bar{X} \cdot \bar{Y} = \frac{11612}{6} - 8,83 \cdot 196,67 = 1935,33 - 1736,59 = 198,74$$

Parametri:

$$b = \frac{C_{XY}}{\sigma_x^2} = \frac{198,74}{10,2} = 19,48$$


$$a = \bar{Y} - b \cdot \bar{X} = 196,67 - 19,48 \cdot 8,83 = 196,67 - 172,01 = 24,66$$

$$\hat{y}_i = 24,66 + 19,48 \cdot x_i$$

Zašto ovaj korak?

Tumačenje parametara:

- $a = 24,66$: Ako je obim proizvodnje 0 komada, ocijenjeni trošak proizvodnje iznosi **24.660 KM** (fiksni trošak koji postoji neovisno o obimu).
- $b = 19,48$: Ako obim proizvodnje poraste za **1.000 komada**, ocijenjeni trošak proizvodnje će u prosjeku porasti za **19.480 KM**, uz nepromijenjene ostale faktore (*ceteris paribus*).



c) Koeficijent determinacije

$$\sigma_y^2 = \frac{\sum y_i^2}{N} - \bar{Y}^2 = \frac{255336}{6} - 196,67^2 = 42556 - 38679,09 = 3876,91$$

$$r^2 = \frac{C_{XY}^2}{\sigma_x^2 \cdot \sigma_y^2} = \frac{198,74^2}{10,2 \cdot 3876,91} = \frac{39497,19}{39544,49} = \boxed{0,9988}$$

Zašto ovaj korak?

Tumačenje: 99,88% ukupnog varijabiliteta troškova proizvodnje može se objasniti uticajem varijabiliteta obima proizvodnje. Samo 0,12% ostaje neprotumačeno – model je izuzetno reprezentativan.

d) Koeficijent proste linearne korelacije

$$r = \frac{C_{XY}}{\sigma_x \cdot \sigma_y} = \frac{198,74}{\sqrt{10,2 \cdot 3876,91}} = \frac{198,74}{3,194 \cdot 62,26} = \boxed{0,9996}$$

Zašto ovaj korak?

Tumačenje: Koeficijent korelacije $r = 0,9996$ je **blizak 1 i pozitivan**, što znači da je veza između obima i troškova proizvodnje **veoma jaka i pozitivna**. Kako obim raste, troškovi gotovo savršeno linearno rastu.

e) Prognoza troškova za obim od 15.000 komada

$$x_i = 15 \implies \hat{y}_i = 24,66 + 19,48 \cdot 15 = 24,66 + 292,20 = \boxed{316,86 \text{ (000 KM)}}$$

Zašto ovaj korak?


Tumačenje: Za obim proizvodnje od **15.000 komada**, očekujemo da će troškovi proizvodnje iznositi **316.860 KM**.

Primjer 2 – Troškovi reklame i obim prodaje (10 tržnih centara)

Dati podaci (x = troškovi reklame u 000 KM, y = obim prodaje u 000 kom):

Tržni centar	x_i	y_i
A	18	55
B	7	17
C	14	36
D	31	85
E	21	62
F	5	18
G	11	33
H	16	41
I	26	63
J	29	87

a) Dijagram rasipanja



b) Linearna regresiona funkcija i jačina veze

Pomoćna tabela:

x_i	y_i	$x \cdot y$	x^2	y^2	r_x	r_y	$r_x - r_y$	$(r_x - r_y)^2$
18	55	990	324	3025	6	6	0	0
7	17	119	49	289	2	1	1	1
14	36	504	196	1296	4	4	0	0
31	85	2635	961	7225	10	9	1	1
21	62	1302	441	3844	7	7	0	0
5	18	90	25	324	1	2	-1	1
11	33	363	121	1089	3	3	0	0
16	41	656	256	1681	5	5	0	0
26	63	1638	676	3969	8	8	0	0
29	87	2523	841	7569	9	10	-1	1
178	497	10820	3890	30311				4

Izračun:

$$\bar{X} = \frac{178}{10} = 17,8 \quad \bar{Y} = \frac{497}{10} = 49,7$$

$$\sigma_x^2 = \frac{3890}{10} - 17,8^2 = 389 - 316,84 = 72,16$$

$$\sigma_y^2 = \frac{30311}{10} - 49,7^2 = 3031,1 - 2470,09 = 561,01$$

$$C_{XY} = \frac{10820}{10} - 17,8 \cdot 49,7 = 1082 - 884,66 = 197,34$$

$$b = \frac{C_{XY}}{\sigma_x^2} = \frac{197,34}{72,16} = 2,73 \quad a = \bar{Y} - b \cdot \bar{X} = 49,7 - 2,73 \cdot 17,8 = 49,7 - 48,59 = 1,11$$

$$\hat{y}_i = 1,11 + 2,73 \cdot x_i$$

Zašto ovaj korak?

Tumačenje parametara:

- $a = 1,11$: Ako je trošak reklame 0 KM, ocijenjeni obim prodaje iznosi **1.110 komada**.
- $b = 2,73$: Ako trošak reklame poraste za **1.000 KM**, ocijenjeni obim prodaje će u prosjeku porasti za **2.730 komada**, *ceteris paribus*.

Koeficijent determinacije i korelacije:

$$r^2 = \frac{C_{XY}^2}{\sigma_x^2 \cdot \sigma_y^2} = \frac{197,34^2}{72,16 \cdot 561,01} = \frac{38943,08}{40483,44} = 0,9620 \quad \Rightarrow \quad r = \sqrt{0,9620} = \boxed{0,9808}$$

Zašto ovaj korak?

$r = 0,9808$ – **veoma jaka i pozitivna veza**. 96,20% varijabiliteta obima prodaje može se objasniti uticajem troškova reklame.

c) Prognoza obima prodaje za 30.000 KM troškova reklame

$$x_i = 30 \quad \Rightarrow \quad \hat{y}_i = 1,11 + 2,73 \cdot 30 = 1,11 + 81,90 = \boxed{83,01 \text{ (000 kom)}}$$

Zašto ovaj korak?

Tumačenje: Ukoliko se na reklamu utroši **30.000 KM**, procijenjeni obim prodaje će iznositi **83.010 komada**.

d) Spearmanov koeficijent korelacije ranga

Ključni pojam

Spearmanov ρ koristi se kada podaci nisu normalno raspoređeni ili kada imamo ordinalne podatke. Temelji se na rangovima umjesto stvarnih vrijednosti:

$$\rho = 1 - \frac{6 \cdot \sum d_i^2}{N^3 - N}, \quad d_i = r_x - r_y$$

Napomena: Ako se neka vrijednost ponavlja, svakoj od njih se pridružuje aritmetička sredina odgovarajućih rangova. Npr. ako dva podatka dijele mjesta 8 i 9: rang = $\frac{8+9}{2} = 8,5$.

Iz tabele: $\sum d_i^2 = 4$, $N = 10$.

$$\rho = 1 - \frac{6 \cdot 4}{10^3 - 10} = 1 - \frac{24}{990} = 1 - 0,0242 = \boxed{0,9757}$$

Zašto ovaj korak?

$\rho = 0,9757$ – **jaka i pozitivna veza** između rangova troškova reklame i rangova obima prodaje. Rezultat je konzistentan s koeficijentom linearne korelacije $r = 0,9808$.

Primjer 3 – Prodaja prodavača i rezultati psihofizičkog testa (9 prodavača)

Dati podaci (y = mjesečna prodaja u 000 KM, x = rezultat testa):

Prodavač	y_i (prodaja)	x_i (test)
A.A.	10	55
B.B.	11	62
C.C.	29	80
D.D.	12	62
E.E.	20	70
F.F.	13	62
G.G.	24	75
H.H.	18	80
I.I.	15	65

Pomoćna tabela:

y_i	x_i	$x \cdot y$	y_i^2	x_i^2	r_y	r_x	$d = r_y - r_x$	d^2
10	55	550	100	3025	1	1	0	0
11	62	682	121	3844	2	3	-1	1
29	80	2320	841	6400	9	8,5	0,5	0,25
12	62	744	144	3844	3	3	0	0
20	70	1400	400	4900	7	6	1	1
13	62	826	169	3844	4	3	1	1
24	75	1800	576	5625	8	7	1	1
18	80	1440	324	6400	6	8,5	-2,5	6,25
15	65	975	225	4225	5	5	0	0
152	611	10737	2900	42107				10,5

Zašto ovaj korak?

Napomena o rangovima s izjednačenim vrijednostima: Vrijednost testa 62 pojavljuje se 3 puta (B.B., D.D., F.F.) i zauzima mjesta 2, 3, 4. Svakom se dodjeljuje rang $\frac{2+3+4}{3} = 3$. Vrijednost 80 pojavljuje se 2 puta (C.C., H.H.) – mjesta 8 i 9, rang $\frac{8+9}{2} = 8,5$.

a) Koeficijent proste linearne korelacije

$$\bar{Y} = \frac{152}{9} = 16,89 \quad \bar{X} = \frac{611}{9} = 67,89$$

$$\sigma_y^2 = \frac{2900}{9} - 16,89^2 = 322,22 - 285,27 = 36,95$$

$$\sigma_x^2 = \frac{42107}{9} - 67,89^2 = 4678,56 - 4609,05 = 69,50$$

$$C_{XY} = \frac{10737}{9} - 67,89 \cdot 16,89 = 1193 - 1146,37 = 46,63$$

$$r^2 = \frac{C_{XY}^2}{\sigma_y^2 \cdot \sigma_x^2} = \frac{46,63^2}{36,95 \cdot 69,50} = \frac{2174,36}{2568,03} = 0,8467 \implies r = \sqrt{0,8467} = \boxed{0,9202}$$

Zašto ovaj korak?

$r = 0,9202$ – **veoma jaka i pozitivna veza** između rezultata psihofizičkog testa i obima prodaje. Prodavači s boljim rezultatima testa ostvaruju veću mjesečnu prodaju.

b) Spearmanov koeficijent korelacije ranga

Iz tabele: $\sum d_i^2 = 10,5$, $N = 9$.

$$\rho = 1 - \frac{6 \cdot \sum d^2}{N^3 - N} = 1 - \frac{6 \cdot 10,5}{9^3 - 9} = 1 - \frac{63}{720} = 1 - 0,0875 = \boxed{0,9125}$$

Zašto ovaj korak?

$\rho = 0,9125$ – **pozitivna i jaka veza** prema rangovima. Rezultat je konzistentan s koeficijentom linearne korelacije ($r = 0,9202$), što potvrđuje snažnu vezu između sposobnosti prodavača i obima prodaje.

Primjer 4 – Varijable X i Y u periodu 2012–2015.

Dati podaci:

Godina	X	Y
2012	0	6
2013	3	5
2014	5	3
2015	8	2
Ukupno	16	16

Poznate vrijednosti: $\bar{X} = 4$, $\sigma_x^2 = 8,5$, $\bar{Y} = 4$, $\sigma_y^2 = 2,5$, $C_{XY} = -4,5$.

a) Jednačina regresione prave

$$b = \frac{C_{XY}}{\sigma_x^2} = \frac{-4,5}{8,5} = -0,53$$


$$a = \bar{Y} - b \cdot \bar{X} = 4 - (-0,53) \cdot 4 = 4 + 2,12 = 6,12$$

$$\hat{y}_i = 6,12 - 0,53 \cdot x_i$$

Zašto ovaj korak?

Tumačenje parametara:

- $a = 6,12$: Kada je $X = 0$, ocijenjena vrijednost Y iznosi **6,12**.
- $b = -0,53$: Svaki porast X za jednu jedinicu prati prosječno **smanjenje** Y za 0,53 jedinice – negativna veza.



b) Koeficijent determinacije

$$r^2 = \frac{C_{XY}^2}{\sigma_x^2 \cdot \sigma_y^2} = \frac{(-4,5)^2}{8,5 \cdot 2,5} = \frac{20,25}{21,25} = 0,9529$$

Zašto ovaj korak?

Tumačenje: 95,29% ukupnog varijabiliteta varijable Y objašnjeno je uticajem varijable X . Model je visoko reprezentativan.

c) Koeficijent korelacije

$$r = \frac{C_{XY}}{\sigma_x \cdot \sigma_y} = \frac{-4,5}{\sqrt{8,5} \cdot \sqrt{2,5}} = \frac{-4,5}{2,915 \cdot 1,581} = \frac{-4,5}{4,608} = \boxed{-0,9762}$$

Zašto ovaj korak?

$r = -0,9762$ – **jaka negativna veza**. Kako X raste, Y opada – što je vidljivo i iz negativnog parametra b i iz dijagrama rasipanja.

Primjer 5 – Godišnji prihod i troškovi oglašavanja (5 turističkih agencija)

Dati podaci (y = godišnji prihod, x = godišnji izdaci za oglašavanje, u 000 KM):

y_i	x_i	$x \cdot y$	y_i^2	x_i^2
60	2	120	3600	4
75	3	225	5625	9
80	4	320	6400	16
85	5	425	7225	25
88	6	528	7744	36
388	20	1618	30594	90

a) Linearna regresiona funkcija

$$\bar{X} = \frac{20}{5} = 4 \quad \bar{Y} = \frac{388}{5} = 77,6$$

$$\sigma_x^2 = \frac{90}{5} - 4^2 = 18 - 16 = 2$$

$$C_{XY} = \frac{1618}{5} - 4 \cdot 77,6 = 323,6 - 310,4 = 13,2$$


$$b = \frac{C_{XY}}{\sigma_x^2} = \frac{13,2}{2} = 6,6 \quad a = \bar{Y} - b \cdot \bar{X} = 77,6 - 6,6 \cdot 4 = 77,6 - 26,4 = 51,2$$

$$\boxed{\hat{y}_i = 51,2 + 6,6 \cdot x_i}$$

Zašto ovaj korak?

Tumačenje parametara:

- $a = 51,2$: Ako su godišnji izdaci za oglašavanje **0 KM**, ocijenjeni godišnji prihod iznosi **51.200 KM**.
- $b = 6,6$: Ako godišnji izdaci za oglašavanje porastu za **1.000 KM**, ocijenjeni godišnji prihod će u prosjeku porasti za **6.600 KM**, *ceteris paribus*.



b) Koeficijent determinacije

$$\sigma_y^2 = \frac{30594}{5} - 77,6^2 = 6118,8 - 6021,76 = 97,04$$

$$r^2 = \frac{C_{XY}^2}{\sigma_x^2 \cdot \sigma_y^2} = \frac{13,2^2}{2 \cdot 97,04} = \frac{174,24}{194,08} = \boxed{0,8978}$$

Zašto ovaj korak?

Tumačenje: **89,78%** ukupnog varijabiliteta godišnjih prihoda može se objasniti uticajem varijabiliteta godišnjih izdataka za oglašavanje. Model je visoko reprezentativan, ali ne savršen – preostalih 10,22% zavisi od faktora koji nisu u modelu (lokacija agencije, kvalitet usluge itd.).

c) Prognoza prihoda za 8.000 KM izdataka za oglašavanje

$$x_i = 8 \implies \hat{y}_i = 51,2 + 6,6 \cdot 8 = 51,2 + 52,8 = \boxed{104 \text{ (000 KM)} = 104.000 \text{ KM}}$$

Zašto ovaj korak?

Tumačenje: Za godišnje izdatke za oglašavanje od **8.000 KM**, možemo očekivati ukupni godišnji prihod od **104.000 KM**.

Svako rješenje sadrži ključne pojmove, potpun izračun i interpretaciju rezultata.