

Mjere varijacije, oblika distribucije i koncentracije

Potpuna rješenja

Ključni pojam

Pregled ključnih formula:

$$RV = x_{\max} - x_{\min} \quad - \text{raspon varijacije}$$

$$MAD = \frac{1}{N} \sum |x_i - \bar{X}| \cdot f_i \quad - \text{srednje apsolutno odstupanje}$$

$$I_Q = Q_3 - Q_1 \quad - \text{interkvartilno apsolutno odstupanje}$$

$$\sigma^2 = \frac{1}{N} \sum (x_i - \bar{X})^2 \cdot f_i = \frac{1}{N} \sum x_i^2 \cdot f_i - \bar{X}^2 \quad - \text{varijansa}$$

$$\sigma = \sqrt{\sigma^2} \quad - \text{standardna devijacija}$$

$$V = \frac{\sigma}{\bar{X}} \cdot 100\% \quad - \text{koeficijent varijacije}$$

$$V_Q = \frac{I_Q}{Q_3 + Q_1} \cdot 100\% \quad - \text{koeficijent interkvartilnog odstupanja}$$

$$\alpha_3 = \frac{\mu_3}{\sigma^3}, \quad \mu_3 = \frac{1}{N} \sum (x_i - \bar{X})^3 \cdot f_i \quad - \text{koeficijent asimetrije}$$

$$\alpha_4 = \frac{\mu_4}{\sigma^4}, \quad \mu_4 = \frac{1}{N} \sum (x_i - \bar{X})^4 \cdot f_i \quad - \text{koeficijent spljoštenosti}$$

Tumačenje α_3 : > 0 desno asimetrična; < 0 lijevo asimetrična; $= 0$ simetrična.

Tumačenje α_4 : > 3 šiljasta (leptokurtična); < 3 spljoštena (platikurtična); $= 3$ normalna.

Primjer 1 – Sati pripreme testa iz Statistike (15 studenata)

Dati podaci (neuređeni):

5 6 2 7 11 9 3 11 18 7 13 7 22 21 25

Korak 1: Urediti seriju po rastućem redoslijedu

2 3 5 6 7 7 7 9 11 11 13 18 21 22 25

Zašto ovaj korak?

Sortiranje je obavezni prvi korak. Bez uređenog niza ne možemo ispravno odrediti raspon varijacije, medijan ni kvartile.

Korak 2: Aritmetička sredina

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{2 + 3 + 5 + 6 + 7 + 7 + 7 + 9 + 11 + 11 + 13 + 18 + 21 + 22 + 25}{15} = \frac{167}{15} = 11,13$$

Korak 3: Pozicione mjere (kvartili)

Ključni pojam

Za negrupisane podatke kvartil na poziciji k je:

$$Q_r = X_{\frac{r \cdot N}{4}}$$

Ako pozicija nije cijeli broj, uzimamo vrijednost na nižoj poziciji (ili interpoliramo, zavisno od konvencije).

$$Q_1 = X_{\frac{N}{4}} = X_{\frac{15}{4}} = X_{3,75} \approx x_4 = \boxed{6}$$

25% studenata utrošilo je 6 sati ili manje za pripremu, dok 75% utrošilo je više.

$$Q_2 = Me = X_{\frac{N+1}{2}} = X_{\frac{16}{2}} = X_8 = \boxed{9}$$

50% studenata utrošilo je 9 sati ili manje, dok 50% utrošilo je više.

$$Q_3 = X_{\frac{3N}{4}} = X_{\frac{45}{4}} = X_{11,25} \approx x_{12} = \boxed{18}$$

75% studenata utrošilo je 18 sati ili manje, dok 25% utrošilo je više.

Korak 4: Raspon varijacije

Ključni pojam

Raspon varijacije je najjednostavnija mjera raspršenosti. Mjeri samo razliku između krajnjih vrijednosti i ignoriše sve ostale podatke – zato je relativno slaba i nepouzdana mjera.

$$RV = x_{\max} - x_{\min} = 25 - 2 = \boxed{23}$$

Zašto ovaj korak?

$RV = 23$ znači da se raspon trajanja pripreme proteže na 23 sata. Nedostatak: ne govori ništa o raspodjeli između ekstrema – isti RV bi imali i podaci koji su sasvim ravnomjerno raspoređeni i podaci koji su svi grupisani oko jedne vrijednosti.

Korak 5: Varijansa

Ključni pojam

Varijansa σ^2 mjeri prosječno kvadratno odstupanje svakog podatka od aritmetičke sredine. Kvadriramo da bismo izbjegli međusobno poništavanje pozitivnih i negativnih odstupanja.

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{X})^2$$

Pomoćna tabela kvadratnih odstupanja:

x_i	$x_i - \bar{X}$	$(x_i - \bar{X})^2$
2	$2 - 11,13 = -9,13$	83,36
3	$3 - 11,13 = -8,13$	66,10
5	$5 - 11,13 = -6,13$	37,58
6	$6 - 11,13 = -5,13$	26,32
7	$7 - 11,13 = -4,13$	17,06
7	$-4,13$	17,06
7	$-4,13$	17,06
9	$9 - 11,13 = -2,13$	4,54
11	$11 - 11,13 = -0,13$	0,02
11	$-0,13$	0,02
13	$13 - 11,13 = 1,87$	3,50
18	$18 - 11,13 = 6,87$	47,20
21	$21 - 11,13 = 9,87$	97,42
22	$22 - 11,13 = 10,87$	118,16
25	$25 - 11,13 = 13,87$	192,38
Σ		727,78

$$\sigma^2 = \frac{1}{15} \cdot 727,78 = \boxed{48,52}$$

Zašto ovaj korak?

Varijansa iznosi 48,52 kvadratnih sati. Izražena je u kvadratima originalne jedinice mjere (sati²), pa je ne interpretiramo direktno – prelazimo na standardnu devijaciju.

Korak 6: Standardna devijacija

$$\sigma = \sqrt{\sigma^2} = \sqrt{48,52} \approx \boxed{6,97 \text{ sati}}$$

Zašto ovaj korak?

Tumačenje: Prosječno linearno odstupanje pojedinačnog broja sati od prosječnog broja sati iznosi **6,97 sati**. Standardna devijacija je u istim jedinicama kao originalni podaci, pa je smisljena za direktno tumačenje.

Korak 7: Koeficijent varijacije

Ključni pojam

Koeficijent varijacije omogućava poređenje varijabilnosti između skupova s različitim jedinicama ili različitim aritmetičkim sredinama. Općenito: $V < 30\%$ homogen skup; $V \geq 30\%$ heterogen skup.

$$V = \frac{\sigma}{\bar{X}} \cdot 100\% = \frac{6,97}{11,13} \cdot 100\% = \boxed{62,62\%}$$

Zašto ovaj korak?

$V \approx 62,62\%$ – relativno izraženo variranje podataka oko aritmetičke sredine iznosi 62,62%. Kako je $V > 30\%$, zaključujemo da je skup **heterogen** – studenti se znatno razlikuju u broju sati koje su posvetili pripremi.

Primjer 2 – Broj tačnih odgovora na kvizu iz Ekonometrije (25 studenata)


Dati podaci (kviz od 5 pitanja, $N = 25$ studenata):

5	3	2	4	3
2	1	5	0	4
5	4	4	5	3
0	3	3	5	4
3	1	2	5	3

a) Grafički prikaz – Poligon apsolutnih frekvencija

Frekvencijska tabela:

x_i (broj odgovora)	f_i (broj studenata)
0	2
1	2
2	3
3	7
4	5
5	6
Σ	25



Zašto ovaj korak?

Poligon frekvencija prikazuje distribuciju odgovora. Vidimo da je distribucija **lijevo asimetrična** – većina studenata ima 3–5 tačnih odgovora (vrh je pomaknut udesno od sredine skale).

b) Mjere varijacije i oblika distribucije

Osnovna statistička tabela:

x_i	f_i	$x_i - \bar{X}$	$ x_i - \bar{X} \cdot f_i$	$x_i^2 \cdot f_i$	$(x_i - \bar{X})^3 \cdot f_i$	$(x_i - \bar{X})^4 \cdot f_i$
0	2	-3,16	6,32	0	-63,11	199,42
1	2	-2,16	4,32	2	-20,16	43,54
2	3	-1,16	3,48	12	-4,68	5,43
3	7	-0,16	1,12	63	-0,03	0,00
4	5	0,84	4,20	80	2,96	2,49
5	6	1,84	11,04	150	37,38	68,77
Σ	25		30,48	307	-47,64	319,65

Osnovne mjere:

$$\bar{X} = \frac{\sum x_i \cdot f_i}{N} = \frac{0 \cdot 2 + 1 \cdot 2 + 2 \cdot 3 + 3 \cdot 7 + 4 \cdot 5 + 5 \cdot 6}{25} = \frac{79}{25} = 3,16$$

$$M_e = 3, \quad Q_1 = 2, \quad Q_3 = 4$$

Raspon varijacije

$$RV = x_{\max} - x_{\min} = 5 - 0 = \boxed{5}$$

Relativno slaba i nepouzdana mjera – uzima u obzir samo dvije krajnje vrijednosti.

Srednje apsolutno odstupanje (MAD)

Ključni pojam

MAD mjeri prosječno apsolutno (bez predznaka) odstupanje od aritmetičke sredine:

$$MAD = \frac{1}{N} \sum_{i=1}^n |x_i - \bar{X}| \cdot f_i$$

$$MAD = \frac{1}{25} \cdot 30,48 = \boxed{1,22 \text{ odgovora}}$$

Zašto ovaj korak?

Prosječno apsolutno odstupanje pojedinačnog broja tačnih odgovora od prosječnog broja tačnih odgovora iznosi **1,22 odgovora**.

Interkvartilno apsolutno odstupanje

$$I_Q = Q_3 - Q_1 = 4 - 2 = \boxed{2}$$

Zašto ovaj korak?

Raspon variranja središnjih 50% podataka iznosi 2 odgovora. To znači da polovina studenata ima rezultate u rasponu od 2 do 4 tačna odgovora.

Varijansa

$$\sigma^2 = \frac{1}{N} \sum x_i^2 \cdot f_i - \bar{X}^2 = \frac{307}{25} - 3,16^2 = 12,28 - 9,99 = \boxed{2,29}$$

Zašto ovaj korak?

Prosječno kvadratno odstupanje pojedinačnog broja tačnih odgovora od prosječnog broja tačnih odgovora iznosi 2,29. Varijansa se izražava u kvadratima jedinice mjere varijable, ali je tako ne tumačimo zbog smislenosti rezultata.

Standardna devijacija

$$\sigma = \sqrt{2,29} = \boxed{1,51 \text{ odgovor}}$$

Zašto ovaj korak?

Prosječno linearno odstupanje pojedinačnog broja tačnih odgovora od prosječnog iznosi **1,51 odgovor**.

Koeficijent varijacije

$$V = \frac{\sigma}{\bar{X}} \cdot 100\% = \frac{1,51}{3,16} \cdot 100\% = \boxed{47,78\%}$$

Zašto ovaj korak?

Relativno izraženo variranje podataka oko aritmetičke sredine iznosi 47,78%. Kako je $V > 30\%$, skup je **heterogen** – studenti se znatno razlikuju u broju tačnih odgovora.

Koeficijent interkvartilnog odstupanja

$$V_Q = \frac{I_Q}{Q_3 + Q_1} \cdot 100\% = \frac{2}{4 + 2} \cdot 100\% = \boxed{33,33\%}$$

Zašto ovaj korak?

Relativno izraženo variranje podataka oko medijane iznosi 33,33%. Ova mjera je robusna na ekstremne vrijednosti jer se bazira samo na kvartilima.

Mjere oblika distribucije – Koeficijent asimetrije α_3

Ključni pojam

Koeficijent asimetrije α_3 mjeri smjer i intenzitet nagnutosti distribucije:

$$\mu_3 = \frac{1}{N} \sum (x_i - \bar{X})^3 \cdot f_i, \quad \alpha_3 = \frac{\mu_3}{\sigma^3}$$

$\alpha_3 > 0$: desno asimetrična (rep se proteže udesno)

$\alpha_3 < 0$: lijevo asimetrična (rep se proteže ulijevo)

$\alpha_3 = 0$: simetrična distribucija

$$\mu_3 = \frac{-47,64}{25} = -1,9056$$

$$\alpha_3 = \frac{\mu_3}{\sigma^3} = \frac{-1,9056}{1,51^3} = \frac{-1,9056}{3,4426} = \boxed{-0,5535}$$

Zašto ovaj korak?

$\alpha_3 = -0,5535 < 0 \Rightarrow$ **lijevo asimetrična distribucija**. Rep se proteže ulijevo – ima relativno malo studenata s niskim brojem odgovora (0 i 1), dok je većina studenata postigla 3–5 tačnih odgovora.

Koeficijent spljoštenosti α_4

Ključni pojam

Koeficijent spljoštenosti α_4 uspoređuje oblik distribucije s normalnom:

$$\mu_4 = \frac{1}{N} \sum (x_i - \bar{X})^4 \cdot f_i, \quad \alpha_4 = \frac{\mu_4}{\sigma^4}$$

$\alpha_4 > 3$: šiljasta (leptokurtična)

$\alpha_4 = 3$: normalna (mezokurtična)

$\alpha_4 < 3$: spljoštena (platikurtična)

$$\mu_4 = \frac{319,65}{25} = 12,786$$

$$\alpha_4 = \frac{\mu_4}{\sigma^4} = \frac{12,786}{1,51^4} = \frac{12,786}{5,198} = \boxed{2,46}$$

Zašto ovaj korak?

$\alpha_4 = 2,46 < 3 \Rightarrow$ **spljoštena (platikurtična) distribucija frekvencija**. Distribucija je šira i ravnija od normalne – vrijednosti su više raspoređene u repovima nego što bi to bio slučaj kod normalne distribucije.

Primjer 3 – Dužina radnog staža u preduzeću „X“ (50 radnika)


Dati podaci (grupisani u intervalne razrede):

Razred R_i (godine)	Frekvencija f_i
$[0-5[$	6
$[5-10[$	12
$[10-15[$	18
$[15-20[$	7
$[20-25[$	6
$[25-30]$	1
Σ	50

Ključni pojam

Za grupisane (intervalne) podatke koristimo **sredinu intervala** c_i kao reprezentativnu vrijednost razreda. Sve formule se zatim primjenjuju s parovima (c_i, f_i) .

a) Grafički prikaz – Poligon apsolutnih frekvencija



b) Mjere varijacije i oblika distribucije

Osnovna statistička tabela:

R_i	f_i	c_i	$c_i - \bar{X}$	$ c_i - \bar{X} \cdot f_i$	$c_i^2 \cdot f_i$	$(c_i - \bar{X})^3 \cdot f_i$	$(c_i - \bar{X})^4 \cdot f_i$
[0–5[	6	2,5	–9,8	58,8	37,5	–5647,15	55342,09
[5–10[	12	7,5	–4,8	57,6	675,0	–1327,10	6370,10
[10–15[	18	12,5	0,2	3,6	2812,5	0,14	0,03
[15–20[	7	17,5	5,2	36,4	2143,75	984,26	5118,13
[20–25[	6	22,5	10,2	61,2	3037,5	6367,25	64945,93
[25–30]	1	27,5	15,2	15,2	756,25	3511,81	53379,48
Σ	50			232,8	9462,5	3889,21	185155,76

Osnovne mjere:

$$\bar{X} = \frac{\sum c_i \cdot f_i}{N} = \frac{6 \cdot 2,5 + 12 \cdot 7,5 + 18 \cdot 12,5 + 7 \cdot 17,5 + 6 \cdot 22,5 + 1 \cdot 27,5}{50} = \frac{615}{50} = 12,3$$

$$M_e = 11,94, \quad Q_1 = 7,71, \quad Q_3 = 16,07, \quad D_1 = 4,17, \quad D_9 = 21,67$$

Raspon varijacije

$$RV = x_{\max} - x_{\min} = 30 - 1 = \boxed{29 \text{ godina}}$$

Srednje apsolutno odstupanje

$$MAD = \frac{1}{N} \sum |c_i - \bar{X}| \cdot f_i = \frac{232,8}{50} = \boxed{4,656 \text{ godina}}$$

Zašto ovaj korak?

Prosječno apsolutno odstupanje pojedinačnih godina radnog staža od prosječnog radnog staža iznosi **4,656 godina**.

Interkvartilno apsolutno odstupanje

$$I_Q = Q_3 - Q_1 = 16,07 - 7,71 = \boxed{8,36 \text{ godina}}$$

Zašto ovaj korak?

Raspon variranja središnjih 50% podataka iznosi 8,36 godina – polovina radnika ima radni staž koji se kreće u rasponu od otprilike 7,71 do 16,07 godina.

Varijansa

$$\sigma^2 = \frac{1}{N} \sum c_i^2 \cdot f_i - \bar{X}^2 = \frac{9462,5}{50} - 12,3^2 = 189,25 - 151,29 = \boxed{37,96}$$

Zašto ovaj korak?

Prosječno kvadratno odstupanje pojedinačnih godina radnog staža od prosječnog radnog staža iznosi 37,96.

Standardna devijacija

$$\sigma = \sqrt{37,96} = \boxed{6,16 \text{ godina}}$$

Zašto ovaj korak?

Prosječno linearno odstupanje pojedinačnih godina radnog staža od prosječnog radnog staža iznosi **6,16 godina**.

Koeficijent varijacije

$$V = \frac{\sigma}{\bar{X}} \cdot 100\% = \frac{6,16}{12,3} \cdot 100\% = \boxed{50,08\%}$$

Zašto ovaj korak?

Relativno izraženo variranje podataka oko aritmetičke sredine iznosi 50,08%. Kako je $V > 30\%$, skup je **heterogen**.

Koeficijent interkvartilnog odstupanja

$$V_Q = \frac{I_Q}{Q_3 + Q_1} \cdot 100\% = \frac{8,36}{16,07 + 7,71} \cdot 100\% = \frac{8,36}{23,78} \cdot 100\% = \boxed{35,97\%}$$

Zašto ovaj korak?

Relativno izraženo variranje podataka oko medijane iznosi 35,97%.

Koeficijent asimetrije

$$\mu_3 = \frac{1}{N} \sum (c_i - \bar{X})^3 \cdot f_i = \frac{3889,21}{50} = 77,78$$

$$\alpha_3 = \frac{\mu_3}{\sigma^3} = \frac{77,78}{6,16^3} = \frac{77,78}{233,89} = \boxed{0,33}$$

Zašto ovaj korak?

$\alpha_3 = 0,33 > 0 \Rightarrow$ **desno asimetrična distribucija**. Rep se proteže udesno – ima relativno malo radnika s dugim radnim stažem (20–30 godina), dok je većina radnika u kategorijama s kraćim stažem.

Koeficijent spljoštenosti

$$\mu_4 = \frac{1}{N} \sum (c_i - \bar{X})^4 \cdot f_i = \frac{185155,76}{50} = 3703,12$$

$$\alpha_4 = \frac{\mu_4}{\sigma^4} = \frac{3703,12}{6,16^4} = \frac{3703,12}{1440,77} = \boxed{2,57}$$

Zašto ovaj korak?

$\alpha_4 = 2,57 < 3 \Rightarrow$ **spljoštena (platikurtična) distribucija**. Distribucija je šira i ravnija od normalne.

Primjer 4 – Ginijev koeficijent i Lorencova kriva (prihodi domaćinstava)

Dati podaci ($N = 77$ domaćinstava):

Prihod po članu (KM)	Broj domaćinstava f_i
300–400	45
400–500	20
500–600	6
600–700	3
700–800	2
800–900	1
Σ	77

a) Ginijev koeficijent

Ključni pojam

Ginijev koeficijent G mjeri nejednakost raspodjele i kreće se između 0 i 1:

- $G = 0$: savršena jednakost (svi imaju isti prihod)
- $G = 1$: savršena nejednakost (jedan subjekt ima sve)

Koristimo **metodu trapeza**:

$$G = 1 - \sum_{i=1}^n (Q_{i-1} + Q_i) \cdot p_i$$

gdje su p_i relativne frekvencije, a Q_i kumulante relativnog agregata.

Proračunska tabela:

R_i	f_i	c_i	p_i	F_i	$c_i \cdot f_i$	$q_i = \frac{c_i f_i}{\sum c_i f_i}$	Q_i
300–400	45	350	0,584	0,584	15750	0,487	0,487
400–500	20	450	0,260	0,844	9000	0,287	0,765
500–600	6	550	0,078	0,922	3300	0,102	0,867
600–700	3	650	0,039	0,961	1950	0,061	0,928
700–800	2	750	0,026	0,987	1500	0,046	0,974
800–900	1	850	0,013	1,000	850	0,026	1,000
Σ	77		1		32350	1	

Zašto ovaj korak?

Objašnjenje kolona: $p_i = f_i/N$ su relativne frekvencije. F_i su kumulativne relativne frekvencije. q_i je udio razreda u ukupnom agregatu (ukupnom prihodu). Q_i je kumulativni relativni agregat – govori nam koliki udio ukupnog prihoda posjeduje donjih $F_i \cdot 100\%$ domaćinstava.

Primjena formule trapeza (polazimo od $Q_0 = 0$):

$$\begin{aligned} G &= 1 - \left[(0 + 0,487) \cdot 0,584 + (0,487 + 0,765) \cdot 0,260 \right. \\ &\quad + (0,765 + 0,867) \cdot 0,078 + (0,867 + 0,928) \cdot 0,039 \\ &\quad \left. + (0,928 + 0,974) \cdot 0,026 + (0,974 + 1,000) \cdot 0,013 \right] \\ &= 1 - \left[0,2844 + 0,3255 + 0,1273 + 0,0700 + 0,0495 + 0,0257 \right] \\ &= 1 - 0,8824 = \boxed{G \approx 0,1176} \end{aligned}$$

Zašto ovaj korak?


Tumačenje: $G \approx 0,12$ je bliže 0 nego 1, što znači da je raspodjela prihoda **relativno ravnomjerna** – koncentracija je slaba. Većina domaćinstava ima slične prihode (45 od 77, tj. skoro 60%, spada u najnižu kategoriju 300–400 KM).

b) Lorencova kriva

Ključni pojam

Lorencova kriva je grafički prikaz kumulativnih relativnih frekvencija (F_i , os x) naspram kumulativnog relativnog agregata (Q_i , os y). **Dijagonala** (linija od $(0,0)$ do $(1,1)$) predstavlja savršenu jednakost. Što je Lorencova kriva bliža dijagonali, to je raspodjela ravnomjernija.

Ginijev koeficijent G = dvostruka površina koncentracije = dvostruka površina između dijagonale i Lorencove krive.



Zašto ovaj korak?

Lorencova kriva je **mnogo bliža liniji potpune jednakosti** nego liniji potpune nejednakosti (os x pa vertikalna na $(1, 1)$). Površina koncentracije (između dijagonale i krive) je relativno mala, što potvrđuje zaključak o slaboj koncentraciji i relativno ravnomjernoj raspodjeli prihoda. $G = 0,12 \approx 2 \cdot \text{površina koncentracije}$.

Primjer 5 – Dužina čekanja putnika (grupisani podaci)

Dati podaci:

Dužina čekanja (min)	Broj putnika f_i
2 – 4	2
4 – 6	14
6 – 8	17
8 – 10	7
Σ	40

Pomoćna tabela:

R_i	f_i	c_i	$c_i - \bar{X}$	$c_i^2 \cdot f_i$	$(c_i - \bar{X})^3 \cdot f_i$
2 – 4	2	3	–3,45	18	–82,13
4 – 6	14	5	–1,45	350	–42,68
6 – 8	17	7	0,55	833	2,83
8 – 10	7	9	2,55	567	116,07
Σ	40			1768	–5,91

$$\bar{X} = \frac{2 \cdot 3 + 14 \cdot 5 + 17 \cdot 7 + 7 \cdot 9}{40} = \frac{6 + 70 + 119 + 63}{40} = \frac{258}{40} = 6,45 \text{ min}$$

a) Raspon varijacije

Ključni pojam

Kod grupisanih podataka koristimo gornju granicu najvećeg razreda i donju granicu najmanjeg:

$$RV = c_{\max} - c_{\min}$$

gdje su $c_{\max}$ i $c_{\min}$ sredine krajnjih razreda.

$$RV = c_{\max} - c_{\min} = 9 - 3 = \boxed{6 \text{ minuta}}$$

Zašto ovaj korak?

Raspon varijacije od 6 minuta govori nam da se ukupna razlika u dužini čekanja između najkraće i najduže kategorije proteže na 6 minuta. Ovo je relativno slaba mjera jer uzima u obzir samo dvije krajnje vrijednosti.

b) Standardna devijacija

$$\sigma^2 = \frac{1}{N} \sum c_i^2 \cdot f_i - \bar{X}^2 = \frac{1768}{40} - 6,45^2 = 44,20 - 41,60 = 2,60$$

$$\sigma = \sqrt{2,60} = \boxed{1,61 \text{ min}}$$

Zašto ovaj korak?

Prosječno linearno odstupanje pojedinačnih dužina čekanja od prosječne dužine čekanja iznosi **1,61 minut**. Putnici u prosjeku čekaju oko 1,61 minutu više ili manje od prosječnih 6,45 minuta.

c) Koeficijent varijacije

$$V = \frac{\sigma}{\bar{X}} \cdot 100\% = \frac{1,61}{6,45} \cdot 100\% = \boxed{24,96\%}$$

Zašto ovaj korak?

Relativno izraženo variranje podataka oko aritmetičke sredine iznosi 24,96%. Kako je $V < 30\%$, zaključujemo da je skup **homogen** – dužine čekanja su relativno ujednačene oko prosječnih 6,45 minuta.

d) Koeficijent asimetrije


$$\mu_3 = \frac{1}{N} \sum (c_i - \bar{X})^3 \cdot f_i = \frac{-5,91}{40} = -0,1478$$

$$\alpha_3 = \frac{\mu_3}{\sigma^3} = \frac{-0,1478}{1,61^3} = \frac{-0,1478}{4,1733} = \boxed{-0,04}$$

Zašto ovaj korak?

$\alpha_3 = -0,04 < 0 \Rightarrow$ **blago negativna (lijevo asimetrična) distribucija**. Koeficijent je iznimno blizak nuli, što znači da je distribucija gotovo simetrična – dužine čekanja su relativno ravnomjerno raspoređene oko srednje vrijednosti od 6,45 minuta.

Vizualizacija – Histogram dužina čekanja



Svako rješenje sadrži ključne pojmove, potpun izračun i interpretaciju rezultata.